



République Algérienne Démocratique et Populaire
Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

Université Abderrahmane Mira – Béjaïa
Faculté des Sciences Exactes – Département Recherche Opérationnelle

**Étude comparative des algorithmes
d'apprentissage supervisé**
appliquer sur le dataset Wine

Présenté par :

Dahmani Mahdi
Chamen Rayane

Année universitaire : 2025–2026

Table des matières

1	Introduction générale	2
2	Présentation du Dataset Wine	2
3	Partie I : Problème de Régression	2
3.1	Régression Linéaire Multiple	2
3.2	Régression SVM (SVR)	3
3.3	Comparaison des modèles	3
3.4	Conclusion	3
4	Partie II : Classification Binaire des Vins	3
4.1	Régression Logistique	3
4.2	SVM Linéaire	4
4.3	Visualisation des frontières de décision	4
4.4	Conclusion	5
5	Partie III : Classification Multi-classes et Réseaux de Neurones	5
5.1	Arbres de Décision et Forêts Aléatoires :	5
5.2	SVM Non-Linéaire :	6
5.3	Réseaux de Neurones Artificiels (MLP) :	7
6	Partie IV : Synthèse Globale	8
7	Conclusion générale	9

1 Introduction générale

Ce travail vise à mettre en pratique plusieurs notions vues en apprentissage supervisé en comparant différentes familles de modèles : régression linéaire, SVM (classification et régression), arbres de décision, forêts aléatoires, ainsi qu’une approche plus récente basée sur les réseaux de neurones (MLP). L’idée principale est d’appliquer tous ces modèles sur un même jeu de données réel (**Wine**) afin d’analyser leurs performances, leurs comportements et leurs limites selon la tâche étudiée.

2 Présentation du Dataset Wine

Le dataset *Wine* est fourni par `scikit-learn`. Il regroupe des mesures chimiques réalisées sur des vins provenant d’une même région, mais produits par trois cultivateurs différents.

- Source : bibliothèque `scikit-learn`
- Taille : 178 observations
- Variables : 13 attributs chimiques (alcool, proline, magnésium, etc.)
- Classes : 3 catégories (cultivateurs 0, 1, 2)

Avant d’entraîner certains modèles (notamment SVM et MLP), une standardisation des variables (centrage-réduction) est nécessaire pour éviter qu’une variable à grande échelle ne domine les autres.

3 Partie I : Problème de Régression

Dans cette première partie, on transforme le problème en **régression** : on ne tient plus compte des classes et on cherche à prédire une valeur continue.

La variable **Alcohol** est utilisée comme **cible** et les 12 autres variables chimiques servent d’entrées du modèle.

Objectif : prédire le taux d’alcool d’un vin à partir de ses caractéristiques chimiques.

- y : taux d’alcool (valeur à prédire)
- X : ensemble des 12 autres attributs

3.1 Régression Linéaire Multiple

La régression linéaire multiple approxime la cible par une combinaison linéaire des variables explicatives. Elle constitue un bon point de départ car elle est simple, rapide et interprétable.

Résultats obtenus :

- $MSE \approx 0.20$
- $R^2 \approx 0.62$

Interprétation Un R^2 proche de 0.62 signifie qu’une part importante de la variabilité de *Alcohol* est expliquée par les variables chimiques utilisées. Cela indique que la relation globale est plutôt proche d’un comportement linéaire, ce qui favorise ce modèle.

3.2 Régression SVM (SVR)

Le modèle **SVR** cherche une fonction de régression qui respecte au mieux les valeurs réelles tout en contrôlant la complexité. Le noyau **RBF** autorise une relation non linéaire entre les variables et la cible.

Optimisation des hyperparamètres Les paramètres C (régularisation) et γ (noyau) ont été ajustés via **GridSearchCV** pour sélectionner la configuration la plus efficace.

Les valeurs retenues :

$$C = 1 \quad \text{et} \quad \gamma = 0.1$$

C règle le compromis entre une erreur d'entraînement faible et un modèle trop complexe. γ contrôle l'influence locale des points sur la forme de la fonction estimée.

Résultats obtenus

- $\text{MSE} \approx 0.21$
- $R^2 \approx 0.60$

3.3 Comparaison des modèles

Même si le SVR est plus flexible (il peut s'adapter à des courbes non linéaires), les scores montrent que la régression linéaire reste légèrement meilleure ici. Cela suggère que l'ajout de complexité n'apporte pas d'amélioration notable sur ce dataset pour la prédiction de *Alcohol*.

3.4 Conclusion

Pour cette tâche, la **régression linéaire multiple** apparaît comme l'option la plus pertinente : elle est simple, stable et fournit les meilleurs indicateurs (MSE plus faible et R^2 plus élevé).

4 Partie II : Classification Binaire des Vins

Ici, on revient à un problème de **classification**, mais en version **binaire** : on conserve uniquement les classes **0** et **1**.

Le but est d'évaluer la capacité de modèles supervisés à distinguer ces deux groupes à partir des variables chimiques.

Objectif : prédire la classe (0 ou 1) d'un vin.

- y : classe (0 ou 1)
- X : attributs chimiques

4.1 Régression Logistique

La régression logistique modélise la probabilité d'appartenance à une classe via une fonction sigmoïde. C'est un modèle de base très utilisé en classification binaire.

Résultats obtenus :

- Accuracy : 0.974

— Matrice de confusion :

$$\begin{bmatrix} 20 & 0 \\ 1 & 18 \end{bmatrix}$$

Interprétation :

Le modèle se trompe très rarement (une seule erreur sur l'ensemble de test présenté), ce qui montre une bonne séparation des classes par les variables disponibles.

4.2 SVM Linéaire

Le SVM linéaire cherche une frontière séparant au mieux les deux classes en maximisant la marge. On teste l'effet du paramètre de régularisation C .

Résultats obtenus :

— SVM Linéaire ($C = 0.1$) : Accuracy = 1.0

$$\begin{bmatrix} 20 & 0 \\ 0 & 19 \end{bmatrix}$$

— SVM Linéaire ($C = 1$) : Accuracy = 1.0

$$\begin{bmatrix} 20 & 0 \\ 0 & 19 \end{bmatrix}$$

— SVM Linéaire ($C = 100$) : Accuracy = 1.0

$$\begin{bmatrix} 20 & 0 \\ 0 & 19 \end{bmatrix}$$

Analyse de l'impact de C :

Les performances ne changent pas selon C . Cela peut s'expliquer par une séparabilité linéaire très claire entre les classes 0 et 1. Dans ce contexte, le SVM trouve une frontière efficace quelle que soit la régularisation testée.

Cependant, une accuracy parfaite sur un jeu de test relativement petit doit être interprétée avec prudence : une validation croisée pourrait renforcer la confiance dans la généralisation.

4.3 Visualisation des frontières de décision

Pour visualiser les décisions des modèles, on retient deux variables explicatives : *Alcohol* et *Proline*.

Méthodologie :

- Standardisation via `StandardScaler`.
- Entraînement uniquement sur les classes 0 et 1.
- Tracé des régions de décision avec `plot_decision_regions` (`mlxtend`).

Résultats :

La figure suivante illustre les régions de décision :




FIGURE 1 – Régions de décision (Alcohol vs Proline) en classification binaire

Interprétation :

Les deux méthodes séparent correctement les classes. Le SVM tend à fournir une séparation plus « stricte » grâce à la maximisation de la marge, tandis que la régression logistique produit une frontière très proche, ce qui confirme que le problème est bien conditionné.

4.4 Conclusion

Dans le cas binaire (classes 0 et 1), les performances sont très élevées. Le dataset semble fortement séparable, ce qui explique l'efficacité de la régression logistique et du SVM linéaire.

5 Partie III : Classification Multi-classes et Réseaux de Neurones

On utilise ici les trois classes (0, 1, 2). L'objectif est de comparer plusieurs modèles multi-classes et d'observer leur robustesse et leurs risques de sur-ajustement.

5.1 Arbres de Décision et Forêts Aléatoires :

Arbre de décision (CART) Un arbre de décision construit des règles successives pour partitionner l'espace des données. Il est intéressant car il est lisible et interprétable.

Résultats obtenus :

$$Accuracy \approx 0.9444$$

Matrice de confusion :

$$\begin{bmatrix} 17 & 2 & 0 \\ 0 & 21 & 0 \\ 0 & 1 & 13 \end{bmatrix}$$

Interprétation :

La majorité des échantillons est correctement classée. Quelques confusions apparaissent, notamment

entre les classes 0 et 2. Un arbre peut sur-apprendre si on ne limite pas sa complexité, ce qui justifie l'intérêt de méthodes d'ensemble.




FIGURE 2 – Visualisation d'un arbre de décision de type CART

Forêt aléatoire La forêt aléatoire combine plusieurs arbres entraînés sur des sous-échantillons et sous-ensembles de variables, ce qui réduit la variance et stabilise les prédictions.

Résultats obtenus :

- Accuracy : 1.0
- Précision, rappel et F1-score : 1.0 pour les 3 classes

Matrice de confusion :

$$\begin{bmatrix} 19 & 0 & 0 \\ 0 & 21 & 0 \\ 0 & 0 & 14 \end{bmatrix}$$

Interprétation :

La performance parfaite s'explique par l'effet d'agrégation des arbres. Néanmoins, sur un dataset de taille modérée, une accuracy de 100% peut aussi signaler un risque de sur-ajustement : une validation croisée serait utile pour confirmer la stabilité.

5.2 SVM Non-Linéaire :

Pour gérer des séparations plus complexes, un SVM à noyau **RBF** est utilisé.

Résultats obtenus :

- Accuracy : 0.9815
- Matrice de confusion :

$$\begin{bmatrix} 19 & 0 & 0 \\ 0 & 18 & 1 \\ 0 & 0 & 20 \end{bmatrix}$$

Interprétation :

Le modèle capture correctement la structure multi-classes. Les erreurs restantes sont limitées, ce qui montre une bonne capacité de séparation avec un noyau non linéaire.

5.3 Réseaux de Neurones Artificiels (MLP) :

Le MLP (perceptron multi-couches) est un modèle flexible, basé sur des couches cachées et une activation non linéaire. Dans ce projet, deux couches cachées sont utilisées, avec *ReLU* et l'optimiseur *Adam*.

Résultats obtenus :

- Accuracy : 1.0
- Précision / rappel / F1-score : 1.0

Interprétation :

Le MLP obtient une performance maximale, preuve qu'il a la capacité de modéliser des relations complexes. Cependant, il reste peu interprétable et peut sur-apprendre si l'architecture n'est pas maîtrisée ou si l'évaluation n'est pas assez robuste.

6 Partie IV : Synthèse Globale

Modèle	Accuracy	Atouts	Points faibles
Arbre de décision	0.963	Lecture intuitive des règles ; interprétable ; rapide à entraîner ; capte des non-linéarités.	Peut sur-ajuster si non régularisé ; erreurs observées surtout entre classes 0 et 2 ; sensible aux petites variations.
Forêt aléatoire	1.0	Très forte performance grâce à l'agrégation ; variance réduite ; prédictions stables ; robuste au bruit.	Interprétation difficile ; temps de calcul plus important ; attention au sur-apprentissage sur petit dataset.
SVM (RBF)	0.9815	Bonne séparation multi-classes via noyau non linéaire ; généralisation généralement solide ; peu d'erreurs.	Choix de C et γ crucial ; modèle peu explicable ; risque de sur-ajustement si paramètres mal choisis.
Réseau de neurones (MLP)	1.0	Modélise efficacement des relations complexes ; très bonne capacité d'adaptation ; performances maximales observées.	Boîte noire (faible interprétabilité) ; réglages sensibles (architecture, itérations) ; sur-apprentissage possible sans validation robuste.

Quel algorithme recommander pour ce type de données (faible dimension, données structurées) et pourquoi ?

Sur un dataset comme *Wine* (peu de variables, données numériques propres, taille modérée), les modèles **simples et bien régularisés** sont souvent un choix sûr.

En régression, la régression linéaire multiple est un bon compromis : elle est stable, rapide et donne de bons scores sans complexité excessive.

En classification binaire, la régression logistique et le SVM linéaire sont très pertinents, car la séparation entre classes est nette et les modèles généralisent bien.

En multi-classes, les modèles plus puissants (forêt, SVM-RBF, MLP) donnent d'excellents résultats, mais il faut garder en tête le risque de sur-ajustement lorsque les scores atteignent 100%. Le meilleur choix dépend donc du compromis recherché : interprétabilité (arbre) vs robustesse (SVM/forêt).

7 Conclusion générale

Au terme de ce projet, nous avons comparé plusieurs approches supervisées sur le dataset *Wine* à travers trois types de tâches : régression, classification binaire et classification multi-classes.

Les expériences montrent que la **régression linéaire** est particulièrement adaptée à la prédiction du taux d'alcool, ce qui confirme que la relation entre variables chimiques et *Alcohol* reste globalement proche du linéaire.

En classification binaire (classes 0 et 1), la performance élevée des modèles (logistique et SVM linéaire) met en évidence une séparabilité simple des données. Malgré cela, il reste utile de rappeler qu'un score parfait sur un test limité ne remplace pas une évaluation plus robuste.

Enfin, pour la classification multi-classes, la forêt aléatoire, le SVM non linéaire et le MLP obtiennent des résultats très élevés, mais ces performances doivent être interprétées avec précaution : sur des jeux de données de taille modérée, des modèles très puissants peuvent apprendre des détails spécifiques au jeu d'entraînement.

Globalement, ce travail illustre qu'il ne faut pas choisir un modèle uniquement parce qu'il est « plus complexe » : un algorithme simple, bien adapté et correctement réglé peut rivaliser avec des méthodes avancées, tout en restant plus interprétable et souvent plus fiable.